Министерство науки и высшего образования Российской Федерации Федеральное государственное бюджетное образовательное учреждение высшего образования «Московский государственный технический университет имени Н.Э. Баумана

(национальный исследовательский университет)» (МГТУ им. Н.Э. Баумана)

Факультет «Информатика и системы управления»

Кафедра ИУ5 «Системы обработки информации и управления»

Курс «Технологии машинного обучения» Лабораторная работа № 4

> Выполнил: студент группы ИУ5-63Б Попов С. Д.

> > Проверил: Гапанюк Ю. Е.

Задание

Выберите набор данных (датасет) для решения задачи классификации или регрессии. В случае необходимости проведите удаление или заполнение пропусков и кодирование категориальных признаков.

С использованием метода train_test_split разделите выборку на обучающую и тестовую. Обучите следующие модели:

- одну из линейных моделей (линейную или полиномиальную регрессию при решении задачи регрессии, логистическую регрессию при решении задачи классификации);
- SVM;
- дерево решений.

Оцените качество моделей с помощью двух подходящих для задачи метрик. Сравните качество полученных моделей. Постройте график, показывающий важность признаков в дереве решений. Визуализируйте дерево решений или выведите правила дерева решений в текстовом виде.

```
In [118... # This Python 3 environment comes with many helpful analytics libraries installed
    # It is defined by the kaggle/python Docker image: https://github.com/kaggle/docker-p
    # For example, here's several helpful packages to load

import numpy as np # linear algebra
import pandas as pd # data processing, CSV file I/O (e.g. pd.read_csv)

# Input data files are available in the read-only "../input/" directory
# For example, running this (by clicking run or pressing Shift+Enter) will list all f.

import os
for dirname, _, filenames in os.walk('/kaggle/input'):
    for filename in filenames:
        print(os.path.join(dirname, filename))

# You can write up to 20GB to the current directory (/kaggle/working/) that gets press
# You can also write temporary files to /kaggle/temp/, but they won't be saved outsid
/kaggle/input/anime-recommendations-database/rating.csv
/kaggle/input/anime-recommendations-database/anime.csv
```

```
import numpy as np
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
%matplotlib inline
sns.set(style="ticks")
```

Кодирование данных и масштабирование

```
In [121... data = pd.read_csv('/kaggle/input/anime-recommendations-database/anime.csv', sep=",")
In [122... data.shape
Out[122... (12294, 7)
In [123... data.head()
```

Out[123	а	nime_id	name		ge	enre	type	episo	des	rating	members							
	0	32281	Kimi no Na wa.	Dram School, S	a, Roma Superna		Movie		1	9.37	200630							
	1	5114	Fullmetal Alchemist: Brotherhood	Action Drama, Far			TV		64	9.26	793665							
	2	28977	Gintama°	Histor	on, Com ical, Par Samurai	ody,	TV		51	9.25	114262							
	3	9253	Steins;Gate	So	ci-Fi, Th	riller	TV		24	9.17	673572							
	4	9969	Gintama'	Histor	on, Com ical, Par Samurai	ody,	TV		51	9.16	151266							
In [124			in ['anime_id', 'nam data.drop(column, ax															
In [125	data	.head()																
Out[125				genre	type	epis	odes	rating	me	mbers								
	0	Dr	rama, Romance, School, S	Supernatural	Movie		1	9.37	2	00630								
	1 A	action, Adv	ction, Adventure, Drama, Fantasy, Magic, Mili TV 64 9.26 793665 ction, Comedy, Historical, Parody, Samurai, S TV 51 9.25 114262															
	2 A	ction, Cor																
	3	Sci-Fi, Thriller TV 24 9.17 673572																
	4 A	ction, Cor	tion, Comedy, Historical, Parody, Samurai, S TV 51 9.16 151266															
In [126	data	ı[[ˈgenre	e']]															
Out[126				ge	enre													
		0	Drama, Romance, Sch	nool, Superna	tural													
		1 Action	n, Adventure, Drama, Fan	tasy, Magic, N	⁄iili						793665 114262 673572							
		2 Action	n, Comedy, Historical, Par	ody, Samurai	, S													
		3		Sci-Fi, Th	riller													
	4 Action, Comedy, Historical, Parody, Samurai, S																	
	•••																	
	1228	12289 Hentai																
	1229				entai													
	122				entai													
	1229				entai													
	12293 Hentai																	
	1229	4 rows × 1	l columns					2294 rows × 1 columns										

In [127... data.isnull().sum()

```
Out[127... genre
                       62
                       25
          type
          episodes
                        0
                      230
          rating
          members
          dtype: int64
In [128... for null_rows in ['genre', 'type', 'rating']:
              data.dropna(subset=[null_rows], inplace=True)
         data.isnull().sum()
In [129...
Out [129... genre
                      0
          type
                      0
          episodes
                      0
                      0
          rating
          members
                      0
          dtype: int64
In [130...
         data.shape
Out [130... (12017, 5)
In [131... data.dtypes.loc[lambda x: x == 'object']
Out[131... genre
                      object
          type
                      object
          episodes
                      object
          dtype: object
In [132...
         genres = [genre for genres in data['genre'] for genre in genres.split(', ')]
         unique genres = np.unique(genres)
         print(len(unique_genres))
         unique_genres
        43
Out[132... array(['Action', 'Adventure', 'Cars', 'Comedy', 'Dementia', 'Demons',
                 'Drama', 'Ecchi', 'Fantasy', 'Game', 'Harem', 'Hentai',
                 'Historical', 'Horror', 'Josei', 'Kids', 'Magic', 'Martial Arts',
                 'Mecha', 'Military', 'Music', 'Mystery', 'Parody', 'Police',
                 'Psychological', 'Romance', 'Samurai', 'School', 'Sci-Fi',
                 'Seinen', 'Shoujo', 'Shoujo Ai', 'Shounen', 'Shounen Ai',
                 'Slice of Life', 'Space', 'Sports', 'Super Power', 'Supernatural',
                 'Thriller', 'Vampire', 'Yaoi', 'Yuri'], dtype='<U13')
In [133...
         for genre in unique_genres:
             data[genre] = 0
         for i, genres in data['genre'].items():
              for genre in genres.split(', '):
                  data.at[i, genre] = 1
         data.drop('genre', axis=1, inplace=True)
         data.head()
```

Out [133...

type episodes rating members Action Adventure Cars Comedy Dementia Demons ...

0	Movie	1	9.37	200630	0	0	0	0	0	0
1	TV	64	9.26	793665	1	1	0	0	0	0
2	TV	51	9.25	114262	1	0	0	1	0	0
3	TV	24	9.17	673572	0	0	0	0	0	0
4	TV	51	9.16	151266	1	0	0	1	0	0

5 rows × 47 columns

```
data.dtypes.loc[lambda x: x == 'object']
In [134...
         type
Out [134...
                       object
                       object
          episodes
          dtype: object
         np.where(data['episodes'] == 'Unknown')[0].shape
In [135...
Out[135... (187,)
         data = data.drop(data[data['episodes'] == 'Unknown'].index)
In [136...
         np.where(data['episodes']=='Unknown')[0].shape
Out [136... (0,)
         data['episodes'] = data['episodes'].map(int)
In [137...
         data['type'].unique()
In [138...
Out[138... array(['Movie', 'TV', 'OVA', 'Special', 'Music', 'ONA'], dtype=object)
In [139...
         from sklearn.preprocessing import OrdinalEncoder
          oe = OrdinalEncoder()
         data[['type']] = oe.fit_transform(data[['type']])
         data.dtypes.loc[lambda x: x == 'object']
Out[139... Series([], dtype: object)
In [140...
         data.dtypes.loc[lambda x: x == 'object']
Out[140... Series([], dtype: object)
In [141...
         data.columns = [str(i) for i in data.columns]
         data.describe()
```

Out[141		type	episodes	rating	members	Action	Adventure	
	count	11830.000000	11830.000000	11830.000000	1.183000e+04	11830.000000	11830.000000	1
	mean	3.037785	12.486729	6.484609	1.851100e+04	0.232291	0.193829	
	std	1.811007	47.097131	1.019147	5.537144e+04	0.422311	0.395313	
	min	0.000000	1.000000	1.670000	1.200000e+01	0.000000	0.000000	
	25%	2.000000	1.000000	5.892500	2.322500e+02	0.000000	0.000000	
	50%	3.000000	2.000000	6.570000	1.589500e+03	0.000000	0.000000	
	75 %	5.000000	12.000000	7.190000	9.832000e+03	0.000000	0.000000	
	max	5.000000	1818.000000	10.000000	1.013917e+06	1.000000	1.000000	

8 rows × 47 columns

```
Предсказание
In [146...
         from sklearn.model_selection import train_test_split
In [147...
         (data['Hentai'] == 1).sum()
Out [147... 1099
        target = data[['Hentai']]
In [148...
         data.drop('Hentai', axis=1, inplace=True)
In [149...
         target.shape
Out[149... (11830, 1)
In [150... X_train, X_test, y_train, y_test = train_test_split(data.values, target.values, test_
In [153... | from typing import Dict
         def accuracy_score_for_classes(
             y_true: np.ndarray,
             y_pred: np.ndarray) -> Dict[int, float]:
             Вычисление метрики accuracy для каждого класса
             y_true - истинные значения классов
             y_pred - предсказанные значения классов
```

```
Возвращает словарь: ключ - метка класса,
    значение - Accuracy для данного класса
    # Для удобства фильтрации сформируем Pandas DataFrame
    d = {'t': y_true, 'p': y_pred}
    df = pd.DataFrame(data=d)
    # Метки классов
    classes = np.unique(y_true)
    # Результирующий словарь
    res = dict()
    # Перебор меток классов
    for c in classes:
        # отфильтруем данные, которые соответствуют
        # текущей метке класса в истинных значениях
        temp_data_flt = df[df['t']==c]
        # расчет ассиracy для заданной метки класса
        temp_acc = accuracy_score(
            temp_data_flt['t'].values,
            temp_data_flt['p'].values)
        # сохранение результата в словарь
        res[c] = temp_acc
    return res
def print_accuracy_score_for_classes(
    y_true: np.ndarray,
    y_pred: np.ndarray):
    Вывод метрики accuracy для каждого класса
    accs = accuracy_score_for_classes(y_true, y_pred)
    if len(accs)>0:
        print('Meτκa \t Accuracy')
    for i in accs:
        print('{} \t {}'.format(i, accs[i]))
```

Логистическая регрессия

```
In [152...
         from sklearn.linear_model import LogisticRegression
         from sklearn.metrics import log_loss, accuracy_score
In [154... | lg = LogisticRegression()
          lg.fit(X_train, y_train.ravel())
Out[154... ▼ LogisticRegression
         LogisticRegression()
In [155...
         pred_y_test_proba = lg.predict_proba(X_test)
         pred_y_test = np.argmax(pred_y_test_proba, axis=1)
In [156... | print_accuracy_score_for_classes(y_test.ravel(), pred_y_test)
        Метка
                 Accuracy
                  0.989242282507016
        0
        1
                  0.868421052631579
In [157... log_loss(y_test.ravel(), pred_y_test)
Out [157... 0.8074022103225739
```

```
In [158... | from sklearn.svm import SVC, NuSVC, LinearSVC, OneClassSVM, SVR, NuSVR, LinearSVR
In [190... def print_metrics_for_different_kernels(kernels, C):
             for kernel in kernels:
                  svc = SVC(kernel=kernel, C=C, probability=True)
                  svc.fit(X_train, y_train.ravel())
                  pred_y_test_proba = svc.predict_proba(X_test)
                  pred_y_test = np.argmax(pred_y_test_proba, axis=1)
                  print('{}\nKernel \t {}'.format('='*10, kernel))
                  print()
                  print('Accuracy')
                  print_accuracy_score_for_classes(y_test.ravel(), pred_y_test)
                  print()
                  log_loss_metric = log_loss(y_test.ravel(), pred_y_test)
                  print('LgLoss \n{}'.format(log_loss_metric))
                  print()
                  print()
In [192...
         print_metrics_for_different_kernels(['poly', 'linear', 'rbf', 'sigmoid'], C=5)
```

```
Accuracy
       Метка Accuracy
          0.980355472404116
            0.868421052631579
       1
       LgLoss
        1.0968482857212323
       ========
       Kernel linear
       Accuracy
       Метка Accuracy
              0.989242282507016
       1
               0.8596491228070176
       LqLoss
       0.8378702182592747
       ========
       Kernel rbf
       Accuracy
       Метка Accuracy
               0.9897100093545369
       1
               0.8771929824561403
       LqLoss
       0.7617001984175225
       Kernel sigmoid
       Accuracy
       Метка Accuracy
                0.999532273152479
       1
                0.0
       LgLoss
       3.488586908752252
        Деревья решений
In [161... from sklearn.tree import DecisionTreeClassifier, export_graphviz
In [162... | clf = DecisionTreeClassifier(random_state=1).fit(X_train, y_train.ravel())
```

```
In [163... pred_y_test_proba = clf.predict_proba(X_test)
    pred_y_test = np.argmax(pred_y_test_proba, axis=1)
In [164... print_accuracy_score_for_classes(y_test.ravel(), pred_y_test)

Metka Accuracy
```

0 0.9831618334892422

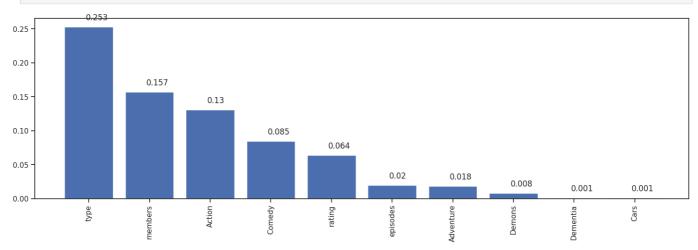
======= Kernel poly

1 0.881578947368421

```
In [165... log_loss(y_test.ravel(), pred_y_test)
Out[165... 0.9597422500060782
         Важность признаков
         sorted(list(zip(data.columns.values, clf.feature_importances_)), key=lambda x: x[1],
Out[177... [('type', 0.2527704183313309),
           ('members', 0.15676888468880124),
           ('Action', 0.13043151984523027),
           ('Comedy', 0.08459507760958529),
           ('Drama', 0.06801037362106936),
           ('rating', 0.06382169379125198),
           ('Sci-Fi', 0.041008477242900916),
           ('Romance', 0.021820434812653947),
           ('episodes', 0.01976404648524759),
           ('Adventure', 0.01840616224590042),
           ('Slice of Life', 0.015427954579995988),
           ('Fantasy', 0.014505256822723554),
           ('Shounen', 0.013716738455562242),
           ('Mystery', 0.011128060612203339),
           ('Ecchi', 0.011105584899657269),
           ('Demons', 0.00826056952277657),
           ('Shoujo', 0.00753455024404381),
           ('Music', 0.006301070869701497),
           ('Horror', 0.006251332476374522),
           ('Supernatural', 0.005863209981800086),
           ('Yuri', 0.005652866878554096),
           ('Military', 0.004976427975172386),
           ('Mecha', 0.004937906598608942),
           ('Magic', 0.004878675236535766),
           ('Kids', 0.004697779665013315),
           ('Psychological', 0.0040314260890299165),
           ('Historical', 0.003432532525161955),
           ('Harem', 0.002115436330680849),
           ('Super Power', 0.0020084065670003823),
           ('Dementia', 0.0012262061568416598),
           ('Cars', 0.0012226519360972077),
           ('Parody', 0.001199002668913009),
           ('School', 0.0007928491034076275),
           ('Sports', 0.0006083677575086863),
           ('Martial Arts', 0.0003161198545848669),
           ('Yaoi', 0.0002398895019780161),
           ('Police', 0.00017203801610060537),
           ('Game', 0.0),
           ('Josei', 0.0),
           ('Samurai', 0.0),
           ('Seinen', 0.0),
           ('Shoujo Ai', 0.0),
           ('Shounen Ai', 0.0),
           ('Space', 0.0),
           ('Thriller', 0.0),
           ('Vampire', 0.0)]
```

```
# Названия признаков
labels = [x for x,_ in sorted_list]
# Важности признаков
data = [x for _,x in sorted_list]
# Вывод графика
fig, ax = plt.subplots(figsize=figsize)
ind = np.arange(len(labels))
plt.bar(ind, data)
plt.xticks(ind, labels, rotation='vertical')
# Вывод значений
for a,b in zip(ind, data):
    plt.text(a-0.05, b+0.01, str(round(b,3)))
plt.show()
return labels, data
```

```
In [175... labels, importance = draw_feature_importances(clf, data, top_feature_num=10 )
```



Визуализация

```
In [183...
         import graphviz
         from sklearn import tree
In [179...
         clf.classes_
Out[179... array([0, 1])
         class_names = ['No Hentai', 'Hentai']
 In [ ]:
In [184...
         tree.export_graphviz(clf, out_file='desision_tree.dot',
                                      feature_names=data.columns.values.tolist(),
                                      class_names=class_names,
                                      filled=True, rounded=True, special_characters=True)
In [186...
         dot_data = export_graphviz(clf, out_file=None,
                                      feature_names=data.columns.values.tolist(),
                                      class_names=class_names,
                                      filled=True, rounded=True, special_characters=True)
         graph = graphviz.Source(dot_data)
         graph
```

